

10.1

```
saula@SAULI:~$ psql --version
psql (PostgreSQL) 18.4 (Ubuntu 18.4-0ubuntu0.26.04.1)
saula@SAULI:~$ pg_config --version
PostgreSQL 18.4 (Ubuntu 18.4-0ubuntu0.26.04.1)
saula@SAULI:~$ sudo systemctl enable --now postgresql
Synchronizing state of postgresql.service with SysV service script with /usr/lib/systemd/systemd-sysv-install.
Executing: /usr/lib/systemd/systemd-sysv-install enable postgresql
Created symlink '/etc/systemd/system/multi-user.target.wants/postgresql.service' -> '/usr/lib/systemd/system/postgresql.service'.
saula@SAULI:~$ sudo -u postgres psql -c "SELECT version();"
          version
-----
PostgreSQL 18.4 (Ubuntu 18.4-0ubuntu0.26.04.1) on x86_64-pc-linux-gnu, compiled by gcc (Ubuntu 15.2.0-16ubuntu1) 15.2.0, 64-bit
(1 row)

saula@SAULI:~$
```

10.2

```
saula@SAULI:~/tmp/pgvector$ pg_config --sharedir
find "$(pg_config --sharedir)/extension" -name "vector.control"
/usr/share/postgresql/18
/usr/share/postgresql/18/extension/vector.control
```

10.3

```
^Csaula@SAULI:~$ sudo -u postgres psql -c \
"CREATE USER rag_user WITH PASSWORD 'rag_password';"
[sudo: authenticate] Password:
CREATE ROLE
saula@SAULI:~$ sudo -u postgres createdb \
--owner=rag_user \
rag_lab
saula@SAULI:~$ sudo -u postgres psql \
-d rag_lab \
-c "CREATE EXTENSION IF NOT EXISTS vector;"
CREATE EXTENSION
saula@SAULI:~$ sudo -u postgres psql \
-d rag_lab \
-c "SELECT extname, extversion FROM pg_extension WHERE extname = 'vector';"
 extname | extversion
-----+-----
vector   | 0.8.5
(1 row)
```

11.

```

saúl@SAULI:~$ ollama list
NAME                                ID                                SIZE    MODIFIED
qwen3-embedding:0.6b               ac6da0dfba84                     639 MB  2 minutes ago
qwen3:4b-instruct                   0edcdef34593                     2.5 GB  4 minutes ago
saúl@SAULI:~$ ollama run qwen3:4b-instruct \
  "Responda únicamente: Ollama funciona correctamente."
Ollama funciona correctamente.

saúl@SAULI:~$ curl -s http://localhost:11434/api/embed \
  -H "Content-Type: application/json" \
  -d '{
    "model": "qwen3-embedding:0.6b",
    "input": "Prueba de búsqueda semántica"
  }' |
python3 -c \
  'import json,sys; print(len(json.load(sys.stdin)["embeddings"])[0]))'
1024

```

12 y 13

```

saúl@SAULI:~/lab-rag-local$ cd documentos/
saúl@SAULI:~/lab-rag-local/documentos$ ls
saúl@SAULI:~/lab-rag-local/documentos$ nano hospedaje_web.md
saúl@SAULI:~/lab-rag-local/documentos$ nano hpc.md
saúl@SAULI:~/lab-rag-local/documentos$ nano sso.md
saúl@SAULI:~/lab-rag-local/documentos$ nano balanceador_waf.md
saúl@SAULI:~/lab-rag-local/documentos$ nano firma_digital.md

```

14

```

saúl@SAULI:~/lab-rag-local$ python3 -m venv .venv
saúl@SAULI:~/lab-rag-local$ source .venv/bin/activate
(.venv) saúl@SAULI:~/lab-rag-local$ nano requirements.txt
(.venv) saúl@SAULI:~/lab-rag-local$ python -m pip install --upgrade pip
Requirement already satisfied: pip in ./venv/lib/python3.14/site-packages (25.1.1)
Collecting pip
  Using cached pip-26.1.2-py3-none-any.whl.metadata (4.6 kB)
Using cached pip-26.1.2-py3-none-any.whl (1.8 MB)
Installing collected packages: pip
  Attempting uninstall: pip
    Found existing installation: pip 25.1.1
    Uninstalling pip-25.1.1:
      Successfully uninstalled pip-25.1.1
  Successfully installed pip-26.1.2

```

```
(.venv) saula@SAULI:~/lab-rag-local$ pip install -r requirements.txt
Collecting numpy (from -r requirements.txt (line 1))
  Using cached numpy-2.5.1-cp314-cp314-manylinux_2_27_x86_64.manylinux_2_28_x86_64.whl.metadata (6.6 kB)
Collecting pgvector (from -r requirements.txt (line 2))
  Using cached pgvector-0.5.0-py3-none-any.whl.metadata (19 kB)
Collecting python-dotenv (from -r requirements.txt (line 4))
  Using cached python_dotenv-1.2.2-py3-none-any.whl.metadata (27 kB)
Collecting requests (from -r requirements.txt (line 5))
  Using cached requests-2.34.2-py3-none-any.whl.metadata (4.8 kB)
Collecting psycopg[binary] (from -r requirements.txt (line 3))
  Using cached psycopg-3.3.4-py3-none-any.whl.metadata (4.3 kB)
Collecting psycopg-binary==3.3.4 (from psycopg[binary]->-r requirements.txt (line 3))
  Using cached psycopg_binary-3.3.4-cp314-cp314-manylinux2014_x86_64.manylinux_2_17_x86_64.whl.metadata (2.7 kB)
Collecting charset_normalizer<4,>=2 (from requests->-r requirements.txt (line 5))
  Using cached charset_normalizer-3.4.9-cp314-cp314-manylinux2014_x86_64.manylinux_2_17_x86_64.manylinux_2_28_x86_64.whl.metadata (41 kB)
Collecting idna<4,>=2.5 (from requests->-r requirements.txt (line 5))
  Using cached idna-3.18-py3-none-any.whl.metadata (6.1 kB)
Collecting urllib3<3,>=1.26 (from requests->-r requirements.txt (line 5))
  Using cached urllib3-2.7.0-py3-none-any.whl.metadata (6.9 kB)
Collecting certifi>=2023.5.7 (from requests->-r requirements.txt (line 5))
  Using cached certifi-2026.7.22-py3-none-any.whl.metadata (2.5 kB)
Using cached numpy-2.5.1-cp314-cp314-manylinux_2_27_x86_64.manylinux_2_28_x86_64.whl (16.7 MB)
Using cached pgvector-0.5.0-py3-none-any.whl (39 kB)
Using cached psycopg-3.3.4-py3-none-any.whl (213 kB)
Using cached psycopg_binary-3.3.4-cp314-cp314-manylinux2014_x86_64.manylinux_2_17_x86_64.whl (5.2 MB)
Using cached python_dotenv-1.2.2-py3-none-any.whl (22 kB)
Using cached requests-2.34.2-py3-none-any.whl (73 kB)
Using cached charset_normalizer-3.4.9-cp314-cp314-manylinux2014_x86_64.manylinux_2_17_x86_64.manylinux_2_28_x86_64.whl (223 kB)
Using cached idna-3.18-py3-none-any.whl (65 kB)
Using cached urllib3-2.7.0-py3-none-any.whl (131 kB)
Using cached certifi-2026.7.22-py3-none-any.whl (136 kB)
Installing collected packages: urllib3, python-dotenv, psycopg-binary, psycopg, pgvector, numpy, idna, charset_normalizer, certifi, requests
Successfully installed certifi-2026.7.22 charset_normalizer-3.4.9 idna-3.18 numpy-2.5.1 pgvector-0.5.0 psycopg-3.3.4 psycopg-binary-3.3.4 python-dotenv-1.2.2 requests-2.34.2 urllib3-2.7.0
```

15

```
GNU nano 8.7.1
DATABASE_URL=postgresql://rag_user:rag_password@localhost:5432/rag_lab
OLLAMA_URL=http://localhost:11434
CHAT_MODEL=qwen3:4b-instruct
EMBED_MODEL=qwen3-embedding:0.6b
TOP_K=3
```

16

```
(.venv) saula@SAULI:~/lab-rag-local/src$ ls
cargar_documentos.py
```

17.

```
(.venv) saula@SAULI:~/lab-rag-local$ python src/cargar_documentos.py
Documentos por indexar: 5
Fragmentos generados: 5
Modelo de embeddings: qwen3-embedding:0.6b
Carga finalizada correctamente.
(.venv) saula@SAULI:~/lab-rag-local$ psql -h localhost -U rag_user -d rag_lab \
-c "SELECT id, fuente, fragmento_nro, vector_dims(embedding) AS dimensiones FROM documento_fragmento ORDER BY id;"
Password for user rag_user:
 id |      fuente      | fragmento_nro | dimensiones
-----+-----+-----+-----
  1 | balanceador.waf.md |          1 |         1024
  2 | firma_digital.md  |          1 |         1024
  3 | hospedaje_web.md  |          1 |         1024
  4 | hpc.md            |          1 |         1024
  5 | sso.md            |          1 |         1024
(5 rows)
```

18

```
(.venv) saula@SAULI:~/lab-rag-local/src$ nano consultar_rag.py
```

19.

```
(.venv) saula@SAULI: ~/lab-rag-local$ python src/consultar_rag.py \
    "¿Qué se debe revisar cuando un sitio presenta un error HTTP 503?"

Fragmentos recuperados:
1. hospedaje_web.md (similitud=0.8202)
2. balanceador_waf.md (similitud=0.6922)
3. hpc.md (similitud=0.4670)

Respuesta RAG:
Cuando un sitio presenta un error HTTP 503, se debe revisar si el servidor web responde, si el proceso PHP-FPM está activo, si existe espacio libre en disco y si la base de datos acepta conexiones. También debe revisarse si el error afecta un único sitio o toda la plataforma [Fuente 1].
```

20.

Pregunta 1:

```
(.venv) saula@SAULI: ~/lab-rag-local$ python src/consultar_rag.py \
    "¿Qué se debe revisar cuando un sitio presenta un error HTTP 503?"

Fragmentos recuperados:
1. hospedaje_web.md (similitud=0.8202)
2. balanceador_waf.md (similitud=0.6922)
3. hpc.md (similitud=0.4670)

Respuesta RAG:
Cuando un sitio presenta un error HTTP 503, se debe revisar si el servidor web responde, si el proceso PHP-FPM está activo, si existe espacio libre en disco y si la base de datos acepta conexiones. También debe revisarse si el error afecta un único sitio o toda la plataforma [Fuente 1].
```

Pregunta 2:

```
(.venv) saula@SAULI: ~/lab-rag-local$ python src/consultar_rag.py \
    "¿Qué significa el error invalid_redirect_uri?"

Fragmentos recuperados:
1. sso.md (similitud=0.7240)
2. hospedaje_web.md (similitud=0.4293)
3. balanceador_waf.md (similitud=0.4110)

Respuesta RAG:
El error invalid_redirect_uri significa que la URI de redirección enviada por la aplicación no coincide exactamente con una URI autorizada configurada, incluyendo protocolo, dominio, puerto y ruta [Fuente 1].
```

Pregunta 3:

```
(.venv) saula@SAULI: ~/lab-rag-local$ python src/consultar_rag.py \
    "¿Cómo se diagnostica un trabajo pendiente en HPC?"

Fragmentos recuperados:
1. hpc.md (similitud=0.7253)
2. hospedaje_web.md (similitud=0.3887)
3. balanceador_waf.md (similitud=0.3770)

Respuesta RAG:
Para diagnosticar un trabajo pendiente en HPC, se debe consultar la razón indicada por el planificador. Entre las causas comunes se encuentran falta de recursos, límites de calidad de servicio, dependencia de otro trabajo o solicitud de una partición no disponible. Los comandos de diagnóstico que pueden utilizarse incluyen squeue, sinfo y scontrol show job [Fuente 1].
```

Pregunta 4:

```
(.venv) saula@SAULI: ~/lab-rag-local$ python src/consultar_rag.py \
    "¿Qué evidencia debe conservarse cuando el WAF bloquea una solicitud?"

Fragmentos recuperados:
1. balanceador_waf.md (similitud=0.6278)
2. hospedaje_web.md (similitud=0.4771)
3. hpc.md (similitud=0.4405)

Respuesta RAG:
Cuando el WAF bloquea una solicitud, se debe registrar la fecha, la hora, la dirección solicitada, el método HTTP, el código de respuesta y el identificador de correlación del evento [Fuente 1].
```

Pregunta 5:

```
(.venv) saula@SAULI: ~/lab-rag-local$ python src/consultar_rag.py \
    "¿Qué debe verificarse antes de probar una firma digital?"

Fragmentos recuperados:
1. firma_digital.md (similitud=0.8347)
2. sso.md (similitud=0.3939)
3. hospedaje_web.md (similitud=0.3286)

Respuesta RAG:
Antes de probar una firma digital, debe verificarse que el certificado se encuentre vigente, que el dispositivo criptográfico sea reconocido, que los controladores estén instalados y que la aplicación pueda acceder al proveedor criptográfico. También debe verificar la fecha y hora del equipo [Fuente 1].
```

Pregunta 6:

```
(.venv) saula@SAULI: ~/lab-rag-local$ python src/consultar_rag.py \
    "¿Cómo cambio la contraseña de una red inalámbrica?"

Fragmentos recuperados:
1. sso.md (similitud=0.2929)
2. hospedaje_web.md (similitud=0.2903)
3. firma_digital.md (similitud=0.2515)

Respuesta RAG:
No hay información suficiente en los documentos.
```

21.

Consulta sin RAG

```
✅ **Conclusión**:  
El error HTTP 503 no es un error de cliente, sino de servidor. Se debe investigar **desde el nivel físico hasta el nivel de aplicación**, y priorizar los aspectos que afectan la disponibilidad del servicio (servidor, carga, servicios backend, configuración).  
  
Si el sitio es crítico (como un sitio institucional), es importante tener un **plan de recuperación (disaster recovery)** y un **proceso de monitoreo activo** para detectar y resolver estos errores rápidamente.  
  
¿Quieres que te ayude a crear un guía paso a paso para resolverlo en tu entorno específico? (por ejemplo, con Nginx + PHP + MySQL)
```

Me dio 10 opciones de solución entonces solo incluí la conclusión que sintetiza bien la información

Consulta con RAG

```
(.venv) saula@SAULI: /lab-rag-local$ python src/consultar_rag.py \  
"¿Qué se debe revisar cuando un sitio institucional presenta un error HTTP 503?"  
  
Fragmentos recuperados:  
1. hospedaje_web.md (similitud=0.8052)  
2. balanceador_waf.md (similitud=0.6905)  
3. hpc.md (similitud=0.4645)  
  
Respuesta RAG:  
Cuando un sitio institucional presenta un error HTTP 503, se debe revisar si el servidor web responde, si el proceso PHP-FPM está activo, si existe espacio libre en disco y si la base de datos acepta conexiones. También debe revisarse si el error afecta un único sitio o toda la plataforma [Fuente 1].
```

Criterio	Sin RAG	Con RAG
¿Respondió correctamente?	Si pero abarco el tema de una forma muy general	Si
¿Utilizó los procedimientos suministrados?	Si	Si
¿Incluyó fuentes?	No	Si
¿Inventó información?	No	No
Tiempo aproximado	1 minuto y 30 segundos	3 a 4 segundos
Observaciones	Presenta información de una forma muy general, si hubiese continuado la conversación pude haber sintetizado bien el problema.	Extremadamente rápido y preciso